

Práctica 1

Expresiones regulares, exploración y normalización de datos

Alumno:

Gerardo Martinez Ayala

Angel Ocampo Porcayo

Maestro:

Andres Garcia Floriano

En este reporte se presentan los resultados obtenidos a partir de dos métodos de evaluación de métricas de clasificación binaria: el cálculo manual (Parte I) y el uso de la biblioteca sklearn (Parte II). Ambas partes utilizan el mismo conjunto de datos ficticios:

Datos reales (y_{true}): [0, 1, 1, 0, 1, 0, 1, 0]

Predicciones (y_{pred}): [0, 1, 1, 0, 0, 0, 1, 1]

Parte I: Cálculo manual de las métricas

A partir de los resultados obtenidos manualmente en la Parte I, calculamos varias métricas comunes de clasificación, incluyendo la matriz de confusión y las medidas derivadas de ésta.

Matriz de Confusión:

TP (True Positives - Verdaderos Positivos): 3 (Casos donde la predicción fue 1 y el valor real también era 1).

TN (True Negatives - Verdaderos Negativos): 3 (Casos donde la predicción fue 0 y el valor real también era 0).

FP (False Positives - Falsos Positivos): 1 (Casos donde la predicción fue 1 pero el valor real era 0).

FN (False Negatives - Falsos Negativos): 1 (Casos donde la predicción fue 0 pero el valor real era 1).

Accuracy:

El accuracy se calcula como el número de predicciones correctas dividido por el número total de ejemplos. La fórmula es:

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN) = (3 + 3) / (3 + 3 + 1 + 1) = 0.75$$

El Accuracy de 0.75 indica que el modelo clasificó correctamente el 75% de los ejemplos.

Error:

El error es simplemente 1 menos el accuracy. La fórmula es:

$$\text{Error} = 1 - \text{Accuracy} = 1 - 0.75 = 0.25$$

El Error es del 25%, lo que significa que el 25% de las predicciones fueron incorrectas.

Precision (Positive Predictive Value):

La precision mide la proporción de verdaderos positivos entre todos los ejemplos predichos como positivos. La fórmula es:

$$\text{Precision} = TP / (TP + FP) = 3 / (3 + 1) = 0.75$$

La Precision de 0.75 sugiere que el 75% de las veces en que el modelo predijo la clase positiva (1), la predicción fue correcta.

Recall (True Positive Rate o Sensibilidad):

El recall mide la proporción de verdaderos positivos entre todos los ejemplos que realmente son positivos. La fórmula es:

$$\text{Recall} = TP / (TP + FN) = 3 / (3 + 1) = 0.75$$

El Recall de 0.75 indica que el modelo identificó correctamente el 75% de los ejemplos que eran positivos (clase 1).

True Negative Rate:

El true negative rate mide la proporción de verdaderos negativos entre todos los ejemplos que realmente son negativos. La fórmula es:

$$\text{True Negative Rate} = \text{TN} / (\text{TN} + \text{FP}) = 3 / (3 + 1) = 0.75$$

Este valor muestra que el modelo identificó correctamente el 75% de los ejemplos que eran negativos (clase 0).

False Positive Rate:

El false positive rate mide la proporción de falsos positivos entre todos los ejemplos que realmente son negativos. La fórmula es:

$$\text{False Positive Rate} = \text{FP} / (\text{FP} + \text{TN}) = 1 / (1 + 3) = 0.25$$

El 25% de las predicciones positivas fueron incorrectas, lo que significa que el modelo tuvo falsos positivos en el 25% de las veces que predijo la clase 1.

False Negative Rate:

El false negative rate mide la proporción de falsos negativos entre todos los ejemplos que realmente son positivos. La fórmula es:

$$\text{False Negative Rate} = \text{FN} / (\text{FN} + \text{TP}) = 1 / (1 + 3) = 0.25$$

El 25% de los ejemplos positivos fueron incorrectamente clasificados como negativos.

F1-Score:

El F1-score es la media armónica entre precision y recall, lo que lo convierte en una métrica útil cuando se quiere un equilibrio entre estas dos medidas. La fórmula es:

$$\text{F1-Score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall}) = 2 * (0.75 * 0.75) / (0.75 + 0.75) = 0.75$$

El F1-Score es 0.75, lo que indica un equilibrio entre Precision y Recall. Esta métrica es útil cuando hay una distribución desbalanceada entre las clases.

Parte II: Resultados con sklearn

Los resultados obtenidos utilizando las funciones integradas de sklearn son consistentes con los cálculos manuales de la Parte I.

Matriz de Confusión:

Matriz:

[[3 1]

[1 3]]

Esto confirma los valores de TP, TN, FP y FN: 3, 3, 1 y 1, respectivamente.

Accuracy:

El Accuracy reportado por sklearn es de 0.75, que es exactamente el mismo valor obtenido en la Parte I.

Precision:

La Precision obtenida por sklearn es de 0.75, coincidiendo con la Parte I.

Recall:

El Recall también es de 0.75, igual que en el cálculo manual.

F1-Score:

El F1-Score de 0.75 es idéntico al calculado manualmente.

Interpretación General de los Resultados

En ambos métodos (manual y usando sklearn), las métricas reflejan un desempeño decente del modelo en la clasificación de dos clases. El modelo tiene un Accuracy del 75%, lo que indica que clasifica correctamente la mayoría de los ejemplos. Sin embargo, todavía existe un 25% de error, lo que sugiere que hay margen de mejora.

Análisis de Precision y Recall:

La Precision del 75% indica que, cuando el modelo predice la clase positiva, está correcto en el 75% de las veces, pero también tiene un 25% de falsos positivos (FP).

El Recall del 75% sugiere que el modelo detecta correctamente el 75% de las instancias positivas, aunque deja escapar el 25% de los ejemplos positivos (FN).

F1-Score:

El F1-Score de 0.75 indica un buen equilibrio entre Precision y Recall, lo cual es útil cuando el objetivo es encontrar un balance entre ambas métricas, como en situaciones donde tanto los falsos positivos como los falsos negativos tienen un impacto significativo.

Resultados:

Parte 1:

```
Accuracy: 0.75
Error: 0.25
Precision: 0.75
Recall: 0.75
True Negative Rate: 0.75
False Positive Rate: 0.25
False Negative Rate: 0.25
F1-Score: 0.75
```

Parte 2:

```
Accuracy: 0.75
Precision: 0.75
Recall: 0.75
F1-Score: 0.75
Matriz de confusión:
[[3 1]
 [1 3]]
```

Conclusiones

Los resultados de ambas partes son consistentes y validan el desempeño del modelo. Sin embargo, el 25% de error (Falsos Positivos y Falsos Negativos) sugiere que el modelo podría mejorarse, especialmente si los errores tienen consecuencias importantes en el contexto de la aplicación. La Precision, Recall y F1-Score son métricas útiles para evaluar el comportamiento del modelo en aplicaciones como la detección de fraudes, enfermedades o sistemas de recomendación, donde tanto los falsos positivos como los falsos negativos pueden tener implicaciones costosas.

El uso de bibliotecas como sklearn facilita mucho el cálculo de estas métricas, pero el enfoque manual proporciona una comprensión profunda del proceso y de cómo se derivan cada una de estas métricas.